



PLAN DE DESARROLLO PARA UN SISTEMA DE IA ESPECIALIZADO EN EL ANÁLISIS DE SENTIMIENTOS DE LOS COMENTARIOS DE CLIENTES.

P R E S E N T A

Monserrat Carreño Jiménez

Johan Pichardo García

Rafael Yairjafeth Rojas Nieves

Samuel Hiram Medina Castañeda

Luz María Feregrino Martínez

Julio 2024

ÍNDICE

| | |
|--|-----------|
| INTRODUCCIÓN | 1 |
| 1. IDENTIFICACIÓN Y DELIMITACIÓN DEL PROBLEMA | 3 |
| 1.1. Impacto del problema en la industria: | 3 |
| 2. DEFINICIÓN DE LOS DATOS | 4 |
| 2.1. Descripción del Dataset Teórico..... | 4 |
| 2.2. Columnas y tipos de datos..... | 4 |
| 2.3. Cantidad de datos..... | 5 |
| 3. ANÁLISIS DE SESGO EN LOS DATOS | 5 |
| 3.1. Identificación de sesgos..... | 6 |
| 3.2. Estrategias para mitigar los sesgos | 6 |
| 3.3. Consideraciones éticas..... | 7 |
| 4. SELECCIÓN DEL TIPO DE APRENDIZAJE | 8 |
| 4.1. Justificación del aprendizaje supervisado: | 8 |
| 5. SELECCIÓN DEL MODELO O MODELOS | 10 |
| 5.1. Descripción del modelo o modelos: | 10 |
| 5.2. Justificación de la elección: | 10 |
| 5.3. Explicación del funcionamiento:..... | 10 |
| 5.3.1. Modelo de Análisis de Sentimientos: | 11 |
| 5.3.2. Modelo de Clasificación de Problemas:..... | 12 |
| 5.3.3. Integración de los modelos | 12 |
| 6. ELECCIÓN DEL MÉTODO DE DEPLOYMENT | 13 |
| 6.1. Definición del método de deployment | 13 |
| 6.2. Consideraciones adicionales para el deployment en la nube | 14 |
| CONCLUSIÓN | 15 |
| BIBLIOGRAFÍA | 16 |

INTRODUCCIÓN

En la entidad financiera Santander, se requiere una herramienta para la plataforma VRAC que investigue a sus proveedores actuales y futuros en busca de problemas reputacionales o de estándares. Esto permitirá identificar riesgos y tomar decisiones informadas sobre la colaboración con estos proveedores.

Con el surgimiento de la interacción digital y las redes sociales ha aumentado la voz de los clientes, quienes ahora tienen una infinidad de plataformas para expresar sus opiniones y experiencias. Si bien esta apertura puede ser una valiosa fuente de información para comprender mejor las necesidades del cliente, también presenta un desafío para las entidades o instituciones bancarias que deben gestionar de manera eficiente y efectiva este gran volumen de comentarios. (Kumar, V. & Sharma, M., 2018)

Es aquí donde surge la necesidad de un sistema de inteligencia artificial (IA) especializado en el análisis de sentimientos de los comentarios de clientes. Esta herramienta, al ser capaz de recopilar, procesar y analizar vastas cantidades de datos no estructurados, puede convertirse en un aliado invaluable para las entidades bancarias en su búsqueda por:

- **Identificar y comprender los sentimientos de los clientes:** El sistema de IA puede clasificar los comentarios en categorías de sentimiento como positivo, negativo o neutral, permitiendo a las instituciones bancarias obtener una visión general de la percepción que tienen los clientes sobre sus productos, servicios y atención. (Pang, B & Lee, L., 2008)
- **Detectar problemas recurrentes y áreas de mejora:** Al analizar los comentarios de manera granular, el sistema de IA puede identificar patrones y temas comunes que revelan problemas recurrentes o áreas que requieren atención y mejora. (Liu, 2012)

- **Tomar medidas correctivas de manera oportuna:** Con la información proporcionada por el análisis de sentimientos, las instituciones bancarias pueden tomar medidas proactivas para abordar las quejas de los clientes, resolver problemas y mejorar su experiencia general. (Smith, A & Jones, B., 2023)
- **Fortalecer la reputación y la lealtad del cliente:** Una gestión eficaz de los comentarios de los clientes, demostrada a través de respuestas rápidas y acciones concretas, puede contribuir significativamente a fortalecer la reputación de la institución bancaria, fomentar la lealtad del cliente y generar un impacto positivo en su imagen pública. (Kumar, R & Zhang, X, 2022)

En este documento, se presenta un diseño teórico para el desarrollo de un sistema de IA para el análisis de sentimientos en la industria bancaria. Se abordan aspectos como la definición del problema, la descripción del conjunto de datos, el análisis de sesgos, la selección del tipo de aprendizaje, la elección del modelo, el método de implementación y las conclusiones.

La implementación de un sistema de IA para el análisis de sentimientos en la industria bancaria representa una oportunidad significativa para mejorar la experiencia del cliente, proteger la reputación y tomar decisiones estratégicas basadas en datos. Al comprender mejor las opiniones y preocupaciones de sus clientes, las entidades financieras pueden tomar medidas proactivas para fortalecer su relación con los clientes y fomentar el crecimiento a largo plazo.

1. IDENTIFICACIÓN Y DELIMITACIÓN DEL PROBLEMA

En el contexto del banco Santander, se requiere una herramienta para la plataforma VRAC que investigue a proveedores existentes y futuros en busca de problemas reputacionales o de estándares. Esto permitirá identificar riesgos y tomar decisiones informadas sobre la colaboración con estos proveedores.

El banco Santander necesita asegurar que sus proveedores cumplen con los estándares reputacionales y normativos requeridos. La identificación de problemas reputacionales o de cumplimiento en los proveedores es crucial para minimizar riesgos y mantener la integridad del banco.

La industria bancaria se ve directamente afectada por este problema, ya que las instituciones financieras dependen en gran medida de la confianza y la lealtad de sus clientes para su éxito. La gestión eficaz de los comentarios de los clientes es esencial para mantener una imagen pública positiva, fortalecer las relaciones con los clientes y fomentar el crecimiento a largo plazo. (Asociación Dec-CI, 2024)

1.1. Impacto del problema en la industria:

En la industria bancaria, trabajar con proveedores que tienen problemas reputacionales puede afectar la imagen del banco, reducir la confianza de los clientes y conllevar riesgos regulatorios y financieros. Un sistema de IA que analice estos factores puede mejorar significativamente la gestión de riesgos. (Banxico, 2024)

2. DEFINICIÓN DE LOS DATOS

2.1. Descripción del Dataset Teórico

El Dataset tiene como objetivo principal servir como fuente de datos rica y relevante para que las instituciones bancarias puedan entrenar y evaluar modelos de análisis de sentimiento para comentarios de clientes. Este conjunto de datos debe ser lo suficientemente amplio y diverso para capturar la amplia gama de opiniones y experiencias que los clientes expresan en plataformas digitales.

El Dataset Teórico se compone de dos tipos de datos: datos del comentario y datos del cliente (opcionales), ya que los comentarios pueden ser anónimos.

2.2. Columnas y tipos de datos

Datos del comentario

| Columna | Tipo de Dato | Descripción |
|-------------------|--------------|---|
| ID del comentario | String | Identificador único para cada comentario, permitiendo su seguimiento y análisis individual |
| Fecha | Date | Fecha en que se publicó el comentario, proporcionando contexto temporal para la opinión del cliente. |
| Plataforma | String | Plataforma en la que se encontró el comentario (e.g., Twitter, Facebook, Google Reviews), permitiendo identificar posibles sesgos o tendencias según la plataforma. |
| Comentario | Text | Texto sin procesar del comentario del cliente, preservando la riqueza del lenguaje natural y las expresiones originales. |
| Sentimiento | Categorical | Clasificación del sentimiento del comentario (positivo, negativo, neutral), permitiendo identificar la actitud general del cliente. |

Datos del cliente opcionales

| Columna | Tipo de Dato | Descripción |
|----------------|--------------|--|
| ID del cliente | String | Identificador único para cada cliente, permitiendo vincular comentarios con perfiles individuales (si se dispone de la información). |
| Nombre | String | Nombre del cliente (si se proporciona), aportando contexto adicional a la opinión expresada. |
| Ubicación | String | Ubicación del cliente (si se proporciona), permitiendo identificar posibles patrones geográficos en las opiniones. |
| Edad | Numérico | Edad del cliente (si se proporciona), aportando información demográfica que puede ser relevante para el análisis. |
| Género | String | Género del cliente (si se proporciona), permitiendo identificar posibles diferencias en las opiniones según el género. |

2.3. Cantidad de datos

Para un modelo efectivo, se necesitaría una cantidad significativa de datos. Un dataset inicial de al menos 10,000 comentarios sería ideal para entrenar un modelo robusto de análisis de sentimientos y clasificación de problemas. A medida que el modelo se entrena y se evalúa, se puede ir refinando y aumentando el conjunto de datos con nuevos comentarios para mejorar su rendimiento.

3. ANÁLISIS DE SESGO EN LOS DATOS

La implementación de un sistema de IA para la automatización de la investigación de proveedores en la plataforma VRAC del Banco Santander requiere un análisis profundo de los posibles sesgos presentes en los datos. Estos sesgos podrían afectar la precisión y confiabilidad de los resultados, llevando a decisiones incorrectas y riesgos para el banco. (Manning, C. D. & Sutton, R., 2020)

3.1. Identificación de sesgos

A continuación, se detallan algunos de los sesgos más relevantes a considerar:

- a) **Sesgo de plataforma:** Este sesgo se produce cuando los comentarios de los clientes provienen de diferentes plataformas (redes sociales, sitios web de reseñas, foros, entre otros.) y cada plataforma tiene sus propias características, usuarios y dinámicas. Esto puede generar variaciones significativas en el tono, lenguaje y contenido de los comentarios, afectando el análisis general. (Smith, 2020).
- b) **Sesgo temporal:** Este sesgo se produce cuando la distribución de los comentarios en el tiempo no es uniforme y existen picos o caídas repentinas que pueden afectar el análisis general. Estos eventos pueden estar relacionados con lanzamientos de productos, campañas de marketing, incidentes específicos o cambios en las políticas del proveedor. (Jones, 2018)
- c) **Sesgo demográfico:** Este sesgo se produce cuando los comentarios de los clientes provienen de diferentes grupos demográficos (edad, género, ubicación, nivel educativo, etc.) y cada grupo tiene diferentes patrones de expresión, intereses y expectativas. Esto puede afectar la forma en que los clientes evalúan y comentan sobre los productos o servicios de un proveedor. (García, 2019)

3.2. Estrategias para mitigar los sesgos

Es crucial considerar y mitigar los posibles sesgos que puedan surgir durante el proceso de análisis de datos e inteligencia artificial. A continuación, se detallan algunas estrategias para abordar por cada problemática:

a) Sesgos de plataforma

- **Normalización de datos:** Aplicar técnicas de normalización para estandarizar el formato, escala y contenido de los comentarios provenientes de diferentes plataformas.

- **Análisis por plataforma:** Realizar análisis separados por plataforma para identificar los sesgos específicos de cada una y comprender mejor las dinámicas de cada canal.
- **Consideración de la plataforma en la interpretación:** Al interpretar los resultados del análisis, tener en cuenta la plataforma en la que se generaron los comentarios para comprender mejor su contexto y significado.

b) Sesgo temporal

- **Análisis por período de tiempo:** Segmentar los datos y realizar análisis por períodos de tiempo más cortos para identificar patrones y tendencias temporales.
- **Identificación de eventos:** Identificar y considerar eventos específicos que puedan haber influido en la distribución de los comentarios en el tiempo.
- **Ajuste estacional:** Aplicar técnicas de ajuste estacional para eliminar el ruido y las variaciones causadas por eventos periódicos (por ejemplo, Navidad, Black Friday).

c) Sesgo demográfico

- **Análisis por grupo demográfico:** Realizar análisis por grupos demográficos para identificar patrones y tendencias específicos de cada grupo.
- **Consideración del grupo demográfico en la interpretación:** Al interpretar los resultados del análisis, tener en cuenta el grupo demográfico al que pertenecen los comentarios para comprender mejor su contexto y significado.
- **Enriquecimiento de datos con información demográfica:** Enriquecer los datos de comentarios para comprender mejor las opiniones.

3.3. Consideraciones éticas

La implementación de estrategias para mitigar sesgos en el sistema de IA para la plataforma VRAC del Banco Santander no solo es crucial para garantizar la precisión y confiabilidad de los resultados (Smith, 2020), sino que también conlleva

importantes **consideraciones éticas** que deben ser tomadas en cuenta. Estas consideraciones éticas son fundamentales para un uso responsable y transparente de la IA en la toma de decisiones estratégicas del banco (Jones, 2018), a continuación, se mencionan algunas consideraciones éticas:

- **Transparencia:** Es importante ser transparente sobre el uso de la IA en la evaluación de proveedores y comunicar claramente los criterios y metodologías utilizados.
- **Equidad:** El sistema de IA debe ser diseñado y utilizado de manera justa y equitativa, sin discriminar a ningún proveedor por motivos de tamaño, ubicación, industria o cualquier otra característica irrelevante.
- **Responsabilidad:** Debe existir un sistema claro de responsabilidad para garantizar que el uso de la IA en la evaluación de proveedores se realice de manera ética y responsable.

4. SELECCIÓN DEL TIPO DE APRENDIZAJE

Para la tarea de análisis de proveedores en la plataforma VRAC, el **aprendizaje automático supervisado** es el más adecuado. Se necesitan etiquetar los datos de entrenamiento con categorías de sentimientos y problemas específicos para que el modelo aprenda a identificar patrones en los comentarios. (Hernández, 2021)

4.1. Justificación del aprendizaje supervisado:

- **Disponibilidad de datos etiquetados:** El éxito del aprendizaje supervisado depende en gran medida de la calidad y cantidad de datos etiquetados disponibles. En este caso, se presume que existe un conjunto de datos de comentarios de clientes sobre proveedores, etiquetados con categorías de sentimiento (positivo, negativo, neutral) y problemas específicos (por ejemplo, problemas de servicio al cliente, problemas de calidad del producto, entre otros). (Longo, M & Pol, S., 2022)

- **Tarea de clasificación:** El objetivo del análisis de proveedores es clasificar a los proveedores en función de su reputación y cumplimiento de estándares. El aprendizaje supervisado es particularmente efectivo para tareas de clasificación, donde el modelo aprende a asociar entradas (comentarios de clientes) con salidas (categorías de sentimiento y problemas). (Zarco, 2023)
- **Interpretabilidad de los resultados:** Los modelos de aprendizaje supervisado pueden proporcionar cierta interpretabilidad de los resultados, lo que permite comprender mejor las razones por las que el modelo clasifica a un proveedor de una manera particular. Esto puede ser útil para los usuarios del sistema para tomar decisiones informadas sobre los proveedores. (Ochoa, 2024)

Consideraciones adicionales:

- **Selección del algoritmo de aprendizaje:** Existen diversos algoritmos de aprendizaje supervisado que pueden ser utilizados para esta tarea. La elección del algoritmo adecuado dependerá de la complejidad del problema, la cantidad de datos disponibles y los recursos computacionales disponibles. Algunos algoritmos populares para tareas de clasificación incluyen regresión logística, k-nearest neighbors (KNN), Naive Bayes y SVM (Support Vector Machines). (James, G, Witten, D., Hastie, T., & Tibshirani, R., 2013)
- **Evaluación del modelo:** Es importante evaluar el rendimiento del modelo de aprendizaje supervisado utilizando métricas adecuadas, como precisión, exactitud y recall. Esto permite asegurar que el modelo se comporta de manera efectiva en la tarea de clasificación de proveedores. (Carmona, 2019)

Alternativas al aprendizaje supervisado:

- **Aprendizaje no supervisado:** En caso de que no se disponga de datos etiquetados, se podrían explorar técnicas de aprendizaje no supervisado. Sin embargo, estas técnicas suelen ser más complejas de implementar y pueden no ser tan efectivas para tareas de clasificación como el aprendizaje supervisado. (Domingos, 2015)

- **Aprendizaje por refuerzo:** El aprendizaje por refuerzo podría ser utilizado para entrenar un agente de IA que navegue por la web y recopile información sobre proveedores de manera autónoma. Sin embargo, este enfoque requeriría un desarrollo más complejo del sistema de IA. (Sutton, R. S. & Barto, A. G., 2028)

5. SELECCIÓN DEL MODELO O MODELOS

5.1. Descripción del modelo o modelos:

- **Modelo de Análisis de Sentimientos:** Un modelo basado en redes neuronales recurrentes (RNN) o Transformers (e.g., BERT) para capturar contextos y matices en los comentarios. (Liu B. , 2016)
- **Modelo de Clasificación de Problemas:** Un modelo de clasificación como Support Vector Machine (SVM) o una red neuronal profunda para categorizar los problemas específicos mencionados en los comentarios. (Bengio, Y., Courville, A., & Vincent, P, 2006)

5.2. Justificación de la elección:

- **RNNs y Transformers** son efectivos para el procesamiento de lenguaje natural (NLP) debido a su capacidad para capturar la secuencia y contexto de las palabras en un comentario.
- **SVMs y redes neuronales** son robustos para la clasificación y pueden manejar grandes volúmenes de datos con múltiples clases.

5.3. Explicación del funcionamiento:

- **Análisis de Sentimientos:** El modelo procesa el texto del comentario y predice una etiqueta de sentimiento (positivo, negativo, neutral) basado en los patrones aprendidos durante el entrenamiento. (Medina, 2020)

- **Clasificación de Problemas:** El modelo analiza el contenido del comentario para identificar y clasificar problemas específicos mencionados. (Ruiz)

Para la tarea de análisis de proveedores en la plataforma VRAC, se propone la implementación de un sistema compuesto por dos modelos principales:

5.3.1. Modelo de Análisis de Sentimientos:

- **Tipo de modelo:** Se recomienda utilizar un modelo basado en redes neuronales recurrentes (RNN) o Transformers (por ejemplo, BERT). Estos modelos son particularmente efectivos para tareas de procesamiento de lenguaje natural (NLP) como el análisis de sentimientos, ya que pueden capturar la secuencia y el contexto de las palabras en un comentario. (Liu B. , 2016)
- **Justificación:**
 - **Capacidad de captura de contexto:** Las RNNs y Transformers son capaces de procesar secuencias de palabras y comprender las relaciones entre ellas, lo que es crucial para identificar el sentimiento general de un comentario y las opiniones expresadas por el cliente. (Nassir, F., Dredze, M., Xiang, X., & Jiang, H. , 2020)
 - **Manejo de lenguaje natural:** Estos modelos están entrenados en grandes cantidades de datos de texto, lo que les permite comprender las complejidades del lenguaje natural, incluyendo el sarcasmo, la ironía y las expresiones coloquiales. (Liu B. , 2016)
 - **Flexibilidad:** Los modelos RNNs y Transformers pueden adaptarse a diferentes tareas de NLP (Socher, Manning, C. E., & Ng, A. Y., 2013), incluyendo la clasificación de sentimientos, la extracción de opiniones y la generación de texto.

5.3.2. Modelo de Clasificación de Problemas:

Se propone utilizar un modelo de clasificación robusto como Support Vector Machines (SVM) o una red neuronal profunda. Estos modelos son adecuados para tareas de clasificación como la identificación de problemas específicos mencionados en los comentarios de los clientes.

Justificación:

- **Precisión de clasificación:** Los SVMs y las redes neuronales profundas son conocidos por su alta precisión en tareas de clasificación, incluso con grandes conjuntos de datos y múltiples clases. (Longo, G & Guzzo, T., 2019)
- **Escalabilidad:** Estos modelos pueden manejar grandes volúmenes de datos de manera eficiente, lo que es importante para procesar la gran cantidad de comentarios que pueden generarse sobre los proveedores. (Géron, 2019)
- **Capacidad de aprendizaje:** Los SVMs y las redes neuronales profundas pueden aprender patrones complejos en los datos (Montagnon, Fadili, M., & Cordes, D., 2016), lo que les permite identificar con mayor precisión los problemas específicos mencionados en los comentarios.

5.3.3. Integración de los modelos

Los dos modelos descritos anteriormente se pueden integrar en un sistema de análisis de proveedores de la siguiente manera:

- **Análisis de Sentimientos:** El modelo de análisis de sentimientos procesará cada comentario de cliente y asignará una puntuación de sentimiento (positivo, negativo o neutral). (Jones, 2018)
- **Extracción de problemas:** Para los comentarios con sentimiento negativo, el modelo de clasificación de problemas se utilizará para identificar los problemas específicos mencionados por el cliente. (Chen & Chiang, W., 2019)
- **Generación de informes:** El sistema generará informes que resuman los resultados del análisis, incluyendo la puntuación de sentimiento general para cada proveedor, una lista de los problemas identificados y ejemplos de comentarios relevantes.

6. ELECCIÓN DEL MÉTODO DE DEPLOYMENT

6.1. Definición del método de deployment

Se propone el despliegue de la herramienta de IA en la nube, utilizando plataformas como **Amazon Web Services (AWS)**, **Google Cloud Platform (GCP)** o **Microsoft Azure**. Esta elección se basa en los siguientes beneficios:

Escalabilidad:

- La nube ofrece la capacidad de escalar los recursos computacionales y de almacenamiento de manera elástica, adaptándose a las necesidades cambiantes del análisis de proveedores. Esto permite al Banco Santander manejar grandes volúmenes de datos y solicitudes sin necesidad de realizar inversiones significativas en infraestructura física. (Gartner., 2017)
- La escalabilidad horizontal permite agregar o eliminar recursos de manera rápida y sencilla, sin afectar el funcionamiento del sistema. Esto es crucial para manejar picos de demanda o procesar grandes conjuntos de datos de manera eficiente.

Seguridad:

- Los proveedores de nube líderes como AWS, GCP y Azure ofrecen sólidas medidas de seguridad y cumplimiento de normativas, lo que garantiza la protección de los datos sensibles del Banco Santander. (National Institute of Standards and Technology. Cloud computing security., 2018)
- Estas plataformas cuentan con mecanismos de seguridad física y lógica avanzados, como firewalls, encriptación de datos, control de acceso y auditorías de seguridad.
- Además, los proveedores de nube se adhieren a estrictas normativas de cumplimiento, como PCI DSS, HIPAA y SOC 2, lo que garantiza que los datos del banco se manejan de acuerdo con las mejores prácticas de la industria. (Cloud Security Alliance, 2020).

Facilidad de uso:

- La implementación en la nube facilita la integración con otras herramientas y servicios existentes del Banco Santander, como bases de datos, sistemas de análisis y plataformas de gestión de relaciones con clientes (CRM).
- Los proveedores de nube ofrecen interfaces intuitivas y herramientas de administración que permiten al banco monitorear el rendimiento del sistema, realizar ajustes de configuración y gestionar los recursos de manera eficiente.
- La centralización del acceso y la administración del sistema en la nube simplifica las operaciones y reduce la necesidad de contar con personal técnico especializado en la gestión de infraestructura local.

6.2. Consideraciones adicionales para el deployment en la nube

- **Selección del proveedor de nube:** Es importante evaluar cuidadosamente las características, precios y servicios ofrecidos por cada proveedor de nube antes de tomar una decisión.
- **Modelo de precios:** Se debe elegir un modelo de precios adecuado que se ajuste al presupuesto y las necesidades del Banco Santander. Los proveedores de nube ofrecen diferentes modelos de precios, como pago por uso, reservaciones o suscripciones.
- **Seguridad de datos:** Es fundamental implementar medidas de seguridad adicionales para proteger los datos sensibles del banco, como la encriptación de datos en reposo y en tránsito, el control de acceso basado en roles y la auditoría de actividades.
- **Gobernanza de datos:** Se deben establecer políticas y procedimientos claros para la gestión de datos en la nube, incluyendo la propiedad de los datos, la calidad de los datos y la retención de datos.
- **Integración con sistemas existentes:** Se debe planificar cuidadosamente la integración del sistema de IA con los sistemas y herramientas existentes del Banco Santander para garantizar un flujo de información fluido y una experiencia de usuario óptima.

CONCLUSIÓN

El desarrollo de una herramienta de IA para analizar los comentarios sobre los proveedores del banco Santander es factible y beneficioso. Al implementar esta solución, el banco podrá identificar y mitigar riesgos reputacionales y de cumplimiento, mejorando su gestión de proveedores y manteniendo su reputación e integridad en el mercado.

La implementación de un sistema de IA para la automatización de la investigación de proveedores en la plataforma VRAC del Banco Santander presenta una oportunidad significativa para mejorar la eficiencia y la precisión en la evaluación de proveedores. La IA puede procesar grandes volúmenes de datos de manera rápida y sistemática, extrayendo información relevante de diversas fuentes y aplicando criterios objetivos para evaluar el desempeño de los proveedores.

Sin embargo, es crucial reconocer que la IA no es una solución infalible. Para garantizar la confiabilidad y la justicia en la evaluación de proveedores, es fundamental considerar y mitigar los posibles sesgos que puedan surgir durante el proceso de análisis de datos e inteligencia artificial.

La adopción de estrategias como la diversificación de fuentes de datos, el análisis temporal, la normalización y el balanceo de datos, el monitoreo y la evaluación continua, y la consideración de principios éticos como la transparencia, la equidad y la responsabilidad, son esenciales para minimizar el impacto de los sesgos y garantizar que el sistema de IA se utilice de manera responsable y efectiva.

Al combinar el poder de la IA con un enfoque ético y transparente, el Banco Santander puede transformar la evaluación de proveedores en VRAC en un proceso más justo, eficiente y confiable, contribuyendo a la toma de decisiones estratégicas informadas y al desarrollo de relaciones sólidas con proveedores que aporten valor al negocio.

BIBLIOGRAFÍA

National Institute of Standards and Technology. *Cloud computing security*. (2018).

Obtenido de <https://nvlpubs.nist.gov>:

<https://nvlpubs.nist.gov/nistpubs/legacy/sp/nistspecialpublication800-145.pdf>

Asociación Dec-Cl. (2024). *De la adquisición a la lealtad, la experiencia del cliente como motor de la sostenibilidad empresarial*. Obtenido de <https://asociaciondec-cl.org/>: <https://asociaciondec-cl.org/blog-dec/de-la-adquisicion-a-la-lealtad-la-experiencia-del-cliente-como-motor-de-la-sostenibilidad-empresarial/50524/>

Banxico. (2024). *El objetivo prioritario de Banco de México es mantener una inflación baja y estable*. Obtenido de <https://www.banxico.org.mx/>: <https://www.banxico.org.mx/>

Bengio, Y., Courville, A., & Vincent, P. (2006). Efficient learning of deep architectures for speech recognition. *In Proceedings of the 23rd international conference on machine learning*, 12-119.

Carmona, P. (2019). Evaluación de modelos de aprendizaje automático para la clasificación de sentimientos en Twitter. *Tecnología y Cibernética*, 97-112.

Chen, Y., & Chiang, W. (2019). A sentiment analysis and topic modeling approach for customer review analysis. *Expert Systems with Applications*.

Domingos, P. (2015). The master algorithm: How the quest for the ultimate learning machine will remake our world. . *Basic Books*.

García, D. (2019). *Sesgo demográfico en los sistemas de recomendación: Un desafío para la equidad*. Obtenido de <https://dl.acm.org/>: <https://dl.acm.org/doi/abs/10.1145/3460231.3473897>

Gartner. (2017). *Gartner predicts top cloud trends impacting enterprises in 2018 and beyond*. Obtenido de <https://www.gartner.com>: <https://www.gartner.com/en/newsroom/press-releases/2023-04-19-gartner-forecasts-worldwide-public-cloud-end-user-spending-to-reach-nearly-600-billion-in-2023>

- Géron, M. (2019). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow. *O'Reilly Media*.
- Hernández, R. (2021). Análisis de sentimientos en comentarios de clientes online utilizando técnicas de aprendizaje automático. *Ingeniería y Desarrollo*, 39(1), 123-134.
- James, G, Witten, D., Hastie, T., & Tibshirani, R. (2013). An introduction to statistical learning. Springer.
- Jones, C. (2018). *Mitigación del sesgo temporal en el análisis de series temporales*. Obtenido de <https://www.researchgate.net/>: https://www.researchgate.net/publication/354049603_Assessing_Point_Forecast_Bias_Across_Multiple_Time_Series_Measures_and_Visual_Tools
- Kumar, R, & Zhang, X. (2022). The Impact of Sentiment Analysis on Customer Loyalty in the Banking Sector. *Journal of Business Research*, 148, 106228.
- Kumar, V., & Sharma, M. (2018). Sentiment analysis of customer reviews: A literature review and future directions. *Journal of Retailing and Consumer Services*, 48, 24-33. Obtenido de https://link.springer.com/chapter/10.1007/978-3-7091-1142-0_40.
- Liu, B. (2012). *Sentiment analysis and opinion mining*. . Obtenido de <https://www.amazon.com/Sentiment-Analysis-Synthesis-Lectures-Technologies/dp/1608458849>.
- Liu, B. (2016). Sentiment analysis and opinion mining. *Synthesis Lectures on Data Mining and Knowledge Discovery*, 1-167.
- Longo, G, & Guzzo, T. (2019). Deep learning for customer satisfaction analysis. *In 2019 IEEE International Conference on Data Science and Advanced Computing (DASC)*, 215-220.
- Longo, M, & Pol, S. (2022). Análisis de la reputación online de empresas turísticas mediante técnicas de aprendizaje automático. *Estudios en Turismo y Desarrollo Local*, 24(1), 1-18.
- Manning, C. D., & Sutton, R. (2020). *Natural language processing with Python*. . Obtenido de <https://nlp.stanford.edu/pubs/>: <https://nlp.stanford.edu/pubs/>
- Medina, J. (2020). Análisis de sentimientos en español: Una revisión de enfoques y aplicaciones. *Procesamiento del Lenguaje Natural*, 1-16.

- Montagnon, T., Fadili, M., & Cordes, D. (2016). A deep learning framework for semantic image segmentation. . *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2482-2497.
- Nassir, F., Dredze, M., Xiang, X., & Jiang, H. . (2020). Sentiment analysis on social media for event detection. *In Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*, 1317-1326.
- Ochoa, A. (2024). Un modelo de aprendizaje automático para la detección de fraudes en el comercio electrónico. *Información y Tecnología*, 25(1), 1-12.
- Pang, B, & Lee, L. (2008). *Opinion mining and sentiment analysis*. Obtenido de <https://direct.mit.edu/coli/article/42/3/595/1534/Sentiment-Analysis-Mining-Opinions-Sentiments-and>.
- Ruiz, N. (s.f.). Clasificación de problemas en comentarios de clientes utilizando técnicas de aprendizaje automático. . *Clasificación de problemas en comentarios de clientes utilizando técnicas de aprendizaje automático*. , 5-12.
- Smith, A, & Jones, B. (2023). Leveraging Sentiment Analysis to Enhance Customer Experience in the Banking Industry. *International Journal of Information Management*, 53.
- Smith, A. (2020). *Sesgo en el análisis de datos: Una guía para principiantes*. Obtenido de <https://www.linkedin.com:https://www.linkedin.com/advice/0/what-do-you-your-data-analysis-plagued-biases-skills-data-science-jslie>
- Socher, M., Manning, C. E., & Ng, A. Y. (2013). Sentiment and semantic analysis in the wild. . *Conference on Empirical Methods in Natural Language Processing (EMNLP)* , 804-815.
- Sutton, R. S., & Barto, A. G. (2028). Reinforcement learning: An introduction. MIT press.
- Zarco, M. (2023). Clasificación de artículos de opinión mediante técnicas de aprendizaje automático. *Comunicación y Sociedad*, 30(2), 107-124.